

机器学习课前讲义

复旦粒子物理暑期学校 2026

Machine Learning David Shih (Rutgers University)

课前预习稿 从基础建立 推导写全 英文术语单列

依据 Indico 课表:8 月 17-18 日上午共四讲。本讲义非正式课堂讲义。

Contents

1 如何使用本讲义	3
2 预备知识	3
2.1 线性代数	3
2.2 概率	4
2.3 微积分与链式法则	4
2.4 粒子物理侧需要的最低常识	4
3 机器学习问题的数学表述	4
4 监督学习	5
4.1 回归与分类	5
4.2 最优分类器:Neyman-Pearson	5
4.3 偏差-方差分解(回归)	6
5 损失函数	6
5.1 从极大似然到损失	6
5.2 平方损失	6
5.3 二元交叉熵	6
5.4 多类交叉熵与 softmax	6
5.5 为什么分类不用 MSE?	7
6 梯度下降与优化	7
6.1 批量梯度下降	7
6.2 随机梯度下降(SGD)	7
6.3 学习率、动量、Adam	7
6.4 停止条件	7
7 线性回归:完整推导	8
7.1 岭回归	8
7.2 用梯度下降解线性回归	8
8 逻辑回归:完整推导	9
8.1 模型	9
8.2 损失与梯度	9
8.3 决策边界	9
9 从线性模型到神经网络	9
9.1 为什么要非线性	9
9.2 多层感知机(MLP)	9
9.3 激活函数	10
9.4 万能近似	10

10 反向传播	10
10.1 前向	10
10.2 反向	11
10.3 二分类时只改最后一步	11
11 过拟合、正则化与模型选择	11
11.1 三种数据划分	11
11.2 正则化清单	11
11.3 偏差、容量与物理先验	11
12 分类器性能:ROC、AUC 与物理显著性	12
13 粒子物理中的典型任务	12
13.1 监督分类:喷射标记与信号-本底	12
13.2 回归	12
13.3 生成模型与快速模拟	12
13.4 与模型无关的搜索	12
14 密度估计与生成模型(听课预备)	12
14.1 从直方图到神经网络	13
14.2 条件密度	13
15 弱监督与异常探测:CWoLa 与 CATHODE	13
15.1 问题	13
15.2 CWoLa:用混合样本做弱监督	13
15.3 ANODE	13
15.4 CATHODE	14
15.5 LHC Olympics 与 R&D 数据集	14
16 课堂可能出现的公式与术语	14
17 常见困惑	14
18 听课重点	15
19 进一步学习路线	15
19.1 课前(数小时)	15
19.2 课中对照	16
19.3 课后深入	16
20 英文术语表	17

1 如何使用本讲义

本讲义的目标不是替老师讲完四小时课, 而是让你在走进教室之前, 已经具备下列能力:

1. 能把“训练一个模型”写成明确的数学问题: 数据、假设类、损失函数、优化算法。
2. 能独立推导线性回归的正规方程、逻辑回归的梯度、以及一层神经网络的反向传播。
3. 能用 Neyman–Pearson 引理理解: 粒子物理里“信号/本底分类”的最优解是什么。
4. 听到 *loss*、*overfitting*、*likelihood ratio*、*density estimation*、*weak supervision*、*anomaly detection* 时, 知道它们各自在说哪一层问题。

David Shih 在高能物理机器学习中的代表性工作, 集中在**分类器**、**密度估计**/生成模型以及**与模型无关的异常探测**(如 ANODE、CWoLa hunting、CATHODE)。四讲通常会从神经网络与分类器讲起, 再进入生成模型与异常探测。因此本讲义把前半写成“必须会的基础”, 后半写成“课堂上大概率会用到的物理应用预备”。

听课提示

课堂几乎一定用英文讲。正文用中文讲清楚, **第 20 节**把英文术语集中列出。听课时优先抓: 问题设定(监督/弱监督/无监督)、损失函数、以及“这个方法在逼近哪个似然比”。

课表(Asia/Shanghai):

日期	时间	内容
8 月 17 日(一)	09:30–10:30, 10:50–11:50	Machine Learning
8 月 18 日(二)	09:20–10:20, 10:40–11:40	Machine Learning

2 预备知识

2.1 线性代数

把 n 条样本、每条 d 维特征排成矩阵

$$X = \begin{pmatrix} -\mathbf{x}_1^\top - \\ \vdots \\ -\mathbf{x}_n^\top - \end{pmatrix} \in \mathbb{R}^{n \times d}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n. \quad (1)$$

后面线性回归的正规方程就是对 $X^\top X$ 求逆。你需要熟悉: 矩阵乘法、转置、正定、梯度对向量/矩阵的求导。

对标量函数 $f(\mathbf{w})$, 梯度 $\nabla_{\mathbf{w}} f$ 满足

$$f(\mathbf{w} + \boldsymbol{\epsilon}) = f(\mathbf{w}) + \boldsymbol{\epsilon}^\top \nabla_{\mathbf{w}} f + \mathcal{O}(\|\boldsymbol{\epsilon}\|^2). \quad (2)$$

常用公式(请自己核对一次):

$$\nabla_{\mathbf{w}} (\mathbf{w}^\top \mathbf{a}) = \mathbf{a}, \quad (3)$$

$$\nabla_{\mathbf{w}} \|X\mathbf{w} - \mathbf{y}\|^2 = 2X^\top (X\mathbf{w} - \mathbf{y}). \quad (4)$$

2.2 概率

一条数据 $(\mathbf{x}, y)$ 被看成从未知联合分布 $p_{\text{data}}(\mathbf{x}, y)$ 抽出来的样本。机器学习的“学习”，本质上是用有限样本去逼近这个分布里对我们有用的部分：条件期望、条件概率、或密度本身。

需要的最小工具：

- **期望**: $\mathbb{E}[f(\mathbf{x})] = \int f(\mathbf{x}) p(\mathbf{x}) d\mathbf{x}$; 离散情形改成求和。
- **条件分布**: $p(y | \mathbf{x}) = p(\mathbf{x}, y) / p(\mathbf{x})$ 。
- **贝叶斯**: $p(\theta | \text{data}) \propto p(\text{data} | \theta) p(\theta)$ 。
- **独立同分布 (i.i.d.)**: 训练样本 $(\mathbf{x}_i, y_i)$ 被假定为独立、来自同一分布。这是绝大多数损失函数能写成“样本平均”的理由。

例子 2.1 (伯努利与高斯). 若 $y \in \{0, 1\}$ 且 $P(y = 1 | \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x})$, 则 $y | \mathbf{x}$ 是伯努利分布, 对应逻辑回归。若 $y | \mathbf{x} \sim \mathcal{N}(\mathbf{w}^\top \mathbf{x}, \sigma^2)$, 对应带高斯噪声的线性回归。**损失函数往往就是负对数似然。**

2.3 微积分与链式法则

神经网络训练的全部技术含量, 有很大一部分就是反复使用

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial u} \frac{\partial u}{\partial x}. \quad (5)$$

多层网络只是把 u 换成中间层激活。第 10 节会把这一点写到分量。

2.4 粒子物理侧需要的最低常识

- 对撞机事件是高维的: 四动量、喷射(jet)子结构、缺失能量等构成特征向量 $\mathbf{x}$ 。
- 多数搜索是两类问题: 信号(signal)对本底(background)。
- 本底往往能用模拟或边带数据估计; 真正的新物理信号可能极弱, 且理论模型不一定对。
- 因此除了“用蒙特卡罗训练监督分类器”, 还需要弱监督、无监督、异常探测。

3 机器学习问题的数学表述

定义 3.1 (监督学习的标准设定). 给定训练集

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n, \quad \mathbf{x}_i \in \mathcal{X} \subset \mathbb{R}^d, \quad y_i \in \mathcal{Y}, \quad (6)$$

要在假设类 $\mathcal{H} = \{h_\theta : \mathcal{X} \rightarrow \hat{\mathcal{Y}}\}$ 中选一个函数 h_θ , 使得在**新的**、来自同一分布的样本上误差尽可能小。

三个必须分开的对象：

1. **模型** h_θ : 线性函数、逻辑回归、神经网络、提升树等。 θ 是参数。
2. **损失** $\ell(h_\theta(\mathbf{x}), y)$: 衡量“这一对预测与真值有多糟”。
3. **优化**: 用梯度下降、牛顿法、Adam 等去近似

$$\theta^* \in \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n \ell(h_\theta(\mathbf{x}_i), y_i) + \Omega(\theta). \quad (7)$$

真正关心的是**期望风险**(expected risk)

$$R(\theta) = \mathbb{E}_{(\mathbf{x}, y) \sim p_{\text{data}}} [\ell(h_{\theta}(\mathbf{x}), y)], \quad (8)$$

但 p_{data} 未知, 于是用**经验风险**(empirical risk)

$$\hat{R}_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(h_{\theta}(\mathbf{x}_i), y_i) \quad (9)$$

代替。这就是经验风险最小化(ERM, empirical risk minimization)。

核心要点

机器学习不是“让训练误差为零”。训练误差为零很容易:把模型取得足够复杂即可。目标是**泛化**(generalization):在没见过的数据上仍然好。过拟合就是 $\hat{R}_n$ 很小但 R 仍然大。

按标签 y 是否存在, 问题分成:

- **监督**(supervised): 每条样本都有 y 。分类、回归。
- **无监督**(unsupervised): 只有 $\mathbf{x}$ 。聚类、密度估计、生成模型。
- **弱监督**(weakly supervised): 标签有噪声、或不完整。CWoLa 属于这一类。

4 监督学习

4.1 回归与分类

- 回归: $\mathcal{Y} = \mathbb{R}$ 或 $\mathbb{R}^k$ 。例:用喷射观测量回归顶夸克质量。
- 二分类: $\mathcal{Y} = \{0, 1\}$ 或 $\{+1, -1\}$ 。例:希格斯信号 vs. 本底。
- 多分类: $\mathcal{Y} = \{1, \dots, K\}$ 。例:喷射标记为 $q/g/c/b/t$ 。

分类器常常不直接输出 0/1, 而输出分数 $s(\mathbf{x}) \in \mathbb{R}$ 或概率 $p(y = 1 | \mathbf{x})$ 。最终用阈值 t 做决策:

$$\hat{y}(\mathbf{x}) = \mathbf{1}[s(\mathbf{x}) \geq t]. \quad (10)$$

阈值 t 由工作点(working point)决定:例如固定本底误判率 $\varepsilon_b = 10^{-3}$, 再看信号效率 ε_s 。

4.2 最优分类器:Neyman-Pearson

这是连接统计与机器学习、也是 Shih 讲异常探测时反复回到的定理。

定理 4.1 (Neyman-Pearson). 在两类假设 H_1 (信号 + 本底)与 H_0 (只有本底)之间, 固定第一类错误率(本底被当成信号的概率)时, 使检验力(信号效率)最大的判决, 等价于对似然比设阈值:

$$\Lambda(\mathbf{x}) = \frac{p(\mathbf{x} | H_1)}{p(\mathbf{x} | H_0)} \gtrless t. \quad (11)$$

若把 H_1 想成“来自信号类 S ”、 H_0 想成“来自本底类 B ”, 则最优分数就是

$$s^*(\mathbf{x}) = \frac{p_S(\mathbf{x})}{p_B(\mathbf{x})} \quad \text{或等价地} \quad p(y = 1 | \mathbf{x}) = \frac{p_S(\mathbf{x})}{p_S(\mathbf{x}) + p_B(\mathbf{x})}, \quad (12)$$

最后一式在两类先验相等时成立; 先验不等只是把阈值平移。

听课提示

课堂若出现“classifier is approximating the likelihood ratio”, 指的就是:一个训练好的分类器 $s(\mathbf{x})$ 在理想情况下是 p_S/p_B 的单调函数。后面 CATHODE、CWoLa 的全部聪明之处, 都是在**不直接拥有纯信号样本**时, 仍然去逼近某个有用的似然比。

4.3 偏差-方差分解(回归)

对平方损失, 把预测记为 $\hat{y} = h(\mathbf{x})$, 真值条件期望 $\bar{y}(\mathbf{x}) = \mathbb{E}[y | \mathbf{x}]$, 则

$$\mathbb{E}[(y - \hat{y})^2] = \underbrace{\mathbb{E}[(y - \bar{y})^2]}_{\text{噪声}} + \underbrace{(\mathbb{E}[\hat{y}] - \bar{y})^2}_{\text{偏差}^2} + \underbrace{\mathbb{E}[(\hat{y} - \mathbb{E}[\hat{y}])^2]}_{\text{方差}}. \quad (13)$$

模型太简单: 偏差大。模型太复杂、数据太少: 方差大。正则化是在两者之间折中。

5 损失函数

损失函数 ℓ 决定“什么叫好”。它不是装饰, 而是统计假设的压缩表达。

5.1 从极大似然到损失

假设样本 i.i.d., 模型给出 $p_\theta(y | \mathbf{x})$ 。对数似然为

$$\log p(\mathcal{D} | \theta) = \sum_{i=1}^n \log p_\theta(y_i | \mathbf{x}_i). \quad (14)$$

极大似然估计(MLE)等价于最小化平均负对数似然

$$\mathcal{L}(\theta) = -\frac{1}{n} \sum_{i=1}^n \log p_\theta(y_i | \mathbf{x}_i). \quad (15)$$

所以: 许多常见损失 = 某种概率模型的 NLL。

5.2 平方损失

若 $y | \mathbf{x} \sim \mathcal{N}(h_\theta(\mathbf{x}), \sigma^2)$, 则

$$-\log p(y | \mathbf{x}) = \frac{1}{2\sigma^2} (y - h_\theta(\mathbf{x}))^2 + \text{const}, \quad (16)$$

即均方误差(MSE)

$$\mathcal{L}_{\text{MSE}}(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - h_\theta(\mathbf{x}_i))^2. \quad (17)$$

平方损失对离群点敏感; 物理里若分布有长尾, 有时改用 Huber 损失或分位数损失。

5.3 二元交叉熵

若 $y \in \{0, 1\}$, $p_\theta(y = 1 | \mathbf{x}) = \hat{p}_\theta(\mathbf{x}) \in (0, 1)$, 则

$$p_\theta(y | \mathbf{x}) = \hat{p}^y (1 - \hat{p})^{1-y}, \quad (18)$$

从而

$$\mathcal{L}_{\text{BCE}}(\theta) = -\frac{1}{n} \sum_{i=1}^n \left[y_i \log \hat{p}_\theta(\mathbf{x}_i) + (1 - y_i) \log (1 - \hat{p}_\theta(\mathbf{x}_i)) \right]. \quad (19)$$

这就是二元交叉熵(binary cross-entropy)。逻辑回归、二分类神经网络默认用它。

5.4 多类交叉熵与 softmax

K 类时, 网络输出 logits $\mathbf{z} \in \mathbb{R}^K$,

$$\hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad \mathcal{L}_{\text{CE}} = -\frac{1}{n} \sum_{i=1}^n \log \hat{p}_{y_i}(\mathbf{x}_i). \quad (20)$$

5.5 为什么分类不用 MSE?

可以把 $y \in \{0, 1\}$ 硬套平方损失。但若末层是 sigmoid, MSE 的梯度在饱和区 ($\hat{p} \rightarrow 0$ 或 1) 会消失, 而交叉熵在错误且自信的预测上梯度仍然大。交叉熵还与似然比估计有直接关系, 见第 5.1 节。

命题 5.1 (分类器与似然比). 设两类样本按先验 π_S, π_B 混合, 标签 $y = 1$ 表示信号。则最小化交叉熵的最优解满足

$$\hat{p}^*(\mathbf{x}) = P(y = 1 | \mathbf{x}) = \frac{\pi_S p_S(\mathbf{x})}{\pi_S p_S(\mathbf{x}) + \pi_B p_B(\mathbf{x})}, \quad (21)$$

因而

$$\frac{\hat{p}^*}{1 - \hat{p}^*} = \frac{\pi_S p_S}{\pi_B p_B}. \quad (22)$$

证明: 交叉熵的总体风险是 $\mathbb{E}[-y \log \hat{p} - (1 - y) \log(1 - \hat{p})]$ 。对固定 $\mathbf{x}$, 记 $p = P(y = 1 | \mathbf{x})$, 对 $\hat{p}$ 求导得极值点 $\hat{p} = p$ 。证毕。

这就是“训练分类器 $\approx$ 估计似然比”的精确含义。

6 梯度下降与优化

6.1 批量梯度下降

目标 $\mathcal{L}(\theta)$ 可微时, 最简单的更新是

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t). \quad (23)$$

$\eta > 0$ 是学习率 (learning rate)。一维图像: 若 $\mathcal{L}'(\theta) > 0$, 则 θ 应减小; 故前面有负号。

对凸函数 (如线性回归的 MSE、逻辑回归的 BCE), 适当 η 下会收敛到全局极小。对深度网络, $\mathcal{L}$ 非凸, 梯度下降只保证到临界点; 实践中这已经非常有用。

6.2 随机梯度下降 (SGD)

全数据梯度

$$\nabla \mathcal{L}(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla \ell_i(\theta) \quad (24)$$

在 n 很大时太贵。SGD 每次用一个样本或一个小批量 $\mathcal{B}$:

$$\theta \leftarrow \theta - \eta \cdot \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \nabla \ell_i(\theta). \quad (25)$$

小批量引入噪声, 有时反而有助于逃离尖锐极小值。物理数据集 (喷射图像、点云) 几乎总是用小批量。

6.3 学习率、动量、Adam

- η 太大: 损失震荡或发散; 太小: 学得很慢。
- 动量: $\mathbf{v} \leftarrow \beta \mathbf{v} + (1 - \beta) \nabla \mathcal{L}, \theta \leftarrow \theta - \eta \mathbf{v}$, 沿峡谷加速。
- Adam: 对每个参数用梯度一阶矩与二阶矩做自适应缩放, 是神经网络的默认起点。

例子 6.1 (一维二次函数). $\mathcal{L}(\theta) = \frac{1}{2} a \theta^2, a > 0$ 。则 $\theta_{t+1} = (1 - \eta a) \theta_t$ 。收敛条件是 $0 < \eta < 2/a$ 。这解释了“学习率为何不能随便取大”: 曲率 a 越大, 允许的 η 越小。

6.4 停止条件

实践中看验证集损失。验证损失不再下降就停止 (early stopping)——这本身也是一种正则化。

7 线性回归:完整推导

模型

$$h_{\mathbf{w},b}(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b. \quad (26)$$

把偏置吃进向量:令 $\mathbf{x} \leftarrow (1, \mathbf{x})$, $\mathbf{w} \leftarrow (b, \mathbf{w})$, 于是 $h_{\mathbf{w}}(\mathbf{x}) = \mathbf{w}^\top \mathbf{x}$ 。

平方损失

$$\mathcal{L}(\mathbf{w}) = \frac{1}{2n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 = \frac{1}{2n} (\mathbf{w}^\top \mathbf{X}^\top \mathbf{X} \mathbf{w} - 2\mathbf{y}^\top \mathbf{X} \mathbf{w} + \mathbf{y}^\top \mathbf{y}). \quad (27)$$

对 $\mathbf{w}$ 求导:

$$\nabla_{\mathbf{w}} \mathcal{L} = \frac{1}{n} \mathbf{X}^\top (\mathbf{X} \mathbf{w} - \mathbf{y}). \quad (28)$$

令梯度为零, 得到**正规方程**(normal equation)

$$\mathbf{X}^\top \mathbf{X} \mathbf{w} = \mathbf{X}^\top \mathbf{y}. \quad (29)$$

若 $\mathbf{X}^\top \mathbf{X}$ 可逆(特征线性无关且 $n \geq d$),

$$\mathbf{w}^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{X}^+ \mathbf{y}, \quad (30)$$

其中 $\mathbf{X}^+$ 是 Moore–Penrose 伪逆。这是凸二次问题的唯一全局极小。

注记 7.1 (与最小二乘投影). $\mathbf{X}\mathbf{w}$ 是 $\mathbf{y}$ 在 $\mathbf{X}$ 列空间上的正交投影。残差 $\mathbf{X}\mathbf{w}^* - \mathbf{y}$ 与所有列正交, 正是 $\mathbf{X}^\top (\mathbf{X}\mathbf{w}^* - \mathbf{y}) = 0$ 。

7.1 岭回归

若特征共线, $\mathbf{X}^\top \mathbf{X}$ 接近奇异。加上 L_2 正则

$$\mathcal{L}_\lambda(\mathbf{w}) = \frac{1}{2n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2, \quad (31)$$

得

$$\mathbf{w}_\lambda = (\mathbf{X}^\top \mathbf{X} + n\lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (32)$$

λ 把特征值从 μ 抬到 $\mu + n\lambda$, 矩阵必可逆。这是过拟合控制的最干净例子。

7.2 用梯度下降解线性回归

即使有闭式解, 写 SGD 仍有教学价值:

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \cdot \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} (\mathbf{w}^\top \mathbf{x}_i - y_i) \mathbf{x}_i. \quad (33)$$

神经网络优化就是这一行的非线性推广。

例子 7.1 (一维拟合). $d = 1, h = wx + b$ 。对数据 $\{(x_i, y_i)\}$,

$$\begin{pmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} \begin{pmatrix} b \\ w \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix}. \quad (34)$$

请用手算两三个点验证。课堂若演示 “fit a line”, 就是这个。

8 逻辑回归:完整推导

8.1 模型

sigmoid 函数

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \sigma'(z) = \sigma(z)(1 - \sigma(z)). \quad (35)$$

逻辑回归把分数 $z = \mathbf{w}^\top \mathbf{x}$ 压到 $(0, 1)$:

$$\hat{p}(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x}) = P(y = 1 | \mathbf{x}; \mathbf{w}). \quad (36)$$

8.2 损失与梯度

把 $\hat{p}_i = \sigma(\mathbf{w}^\top \mathbf{x}_i)$ 代入 (19)。对单个样本,

$$\ell(\mathbf{w}) = -y \log \sigma(z) - (1 - y) \log(1 - \sigma(z)), \quad z = \mathbf{w}^\top \mathbf{x}, \quad (37)$$

$$\frac{\partial \ell}{\partial z} = -y(1 - \sigma(z)) + (1 - y)\sigma(z) = \sigma(z) - y. \quad (38)$$

因此

$$\nabla_{\mathbf{w}} \mathcal{L} = \frac{1}{n} \sum_{i=1}^n (\sigma(\mathbf{w}^\top \mathbf{x}_i) - y_i) \mathbf{x}_i. \quad (39)$$

与线性回归梯度同形, 只是把 $\mathbf{w}^\top \mathbf{x}$ 换成了 $\sigma(\mathbf{w}^\top \mathbf{x})$ 。

核心要点

逻辑回归没有线性回归那样的闭式解, 因为 σ 是非线性的。但损失对 $\mathbf{w}$ 是凸的, 梯度下降能到全局最优。凸性来自: BCE 对 logit 是凸的, logit 对 $\mathbf{w}$ 是线性的, 凸函数复合仿射映射仍凸。

8.3 决策边界

$\hat{p} = 1/2$ 当且仅当 $\mathbf{w}^\top \mathbf{x} = 0$ 。所以逻辑回归的决策边界是超平面。它仍是线性分类器; “逻辑” 只改变了概率标定与损失, 没有自动产生弯曲边界。要弯曲边界, 需要非线性特征或神经网络。

例子 8.1 (一维阈值). $x \in \mathbb{R}$, $\hat{p} = \sigma(w(x - x_0))$ 。 w 越大, 概率跃迁越陡, 越接近硬阈值。这对应物理里用一个观测量做 cut。

9 从线性模型到神经网络

9.1 为什么要非线性

XOR 问题: 四点 $(0, 0), (0, 1), (1, 0), (1, 1)$, 标签 $0, 1, 1, 0$ 。任何直线都不能分开两类。若先做一个非线性特征 $\phi(x_1, x_2) = (x_1, x_2, x_1 x_2)$, 线性分类器就够了。神经网络做的事, 就是用数据学习 ϕ 。

9.2 多层感知机(MLP)

一层隐藏层的 MLP:

$$\mathbf{h} = \phi(W_1 \mathbf{x} + \mathbf{b}_1), \quad \mathbf{z} = W_2 \mathbf{h} + \mathbf{b}_2, \quad \hat{\mathbf{y}} = g(\mathbf{z}). \quad (40)$$

其中 ϕ 是逐元激活, g 是输出激活(回归用恒等, 二分类用 sigmoid, 多分类用 softmax)。

深度网络只是把 $\mathbf{h}$ 再送入同样的仿射 + 激活, 重复 L 次:

$$\mathbf{a}^{(0)} = \mathbf{x}, \quad \mathbf{a}^{(\ell)} = \phi(W^{(\ell)} \mathbf{a}^{(\ell-1)} + \mathbf{b}^{(\ell)}). \quad (41)$$

9.3 激活函数

名称	公式	作用
sigmoid	$(1 + e^{-z})^{-1}$	早期隐藏层; 易饱和
tanh	$\tanh z$	零均值, 仍会饱和
ReLU	$\max(0, z)$	现代默认; 梯度简单
GELU / SiLU	平滑版 ReLU	Transformer 常用

没有非线性 ϕ , 无论叠多少层, h 仍是 $\mathbf{x}$ 的仿射函数, 表达力与线性模型相同。

9.4 万能近似

在很弱的条件下, 单隐层 MLP 可以一致逼近紧集上的连续函数。这保证“理论上够用”, 不保证“用有限数据、有限宽度能学到”。深度的好处往往是: 用更少的参数表示某些由多尺度组成的函数。




Figure 1: 最简单的前馈网络。每条边是一个权重, 每个圆圈内先做加权和再做 ϕ 。

10 反向传播

以一层隐藏层、标量输出、平方损失为例, 把链式法则写到底。这是课堂上最容易“以为会、其实没写过”的推导。

10.1 前向

$$z_j = \sum_k W_{jk}^{(1)} x_k + b_j^{(1)}, \quad (42)$$

$$h_j = \phi(z_j), \quad (43)$$

$$u = \sum_j W_j^{(2)} h_j + b^{(2)}, \quad (44)$$

$$\hat{y} = u \quad (\text{回归}), \quad (45)$$

$$\ell = \frac{1}{2}(\hat{y} - y)^2. \quad (46)$$

10.2 反向

$$\frac{\partial \ell}{\partial \hat{y}} = \hat{y} - y, \quad (47)$$

$$\frac{\partial \ell}{\partial W_j^{(2)}} = \frac{\partial \ell}{\partial \hat{y}} h_j, \quad \frac{\partial \ell}{\partial b^{(2)}} = \frac{\partial \ell}{\partial \hat{y}}, \quad (48)$$

$$\frac{\partial \ell}{\partial h_j} = \frac{\partial \ell}{\partial \hat{y}} W_j^{(2)}, \quad (49)$$

$$\frac{\partial \ell}{\partial z_j} = \frac{\partial \ell}{\partial h_j} \phi'(z_j), \quad (50)$$

$$\frac{\partial \ell}{\partial W_{jk}^{(1)}} = \frac{\partial \ell}{\partial z_j} x_k, \quad \frac{\partial \ell}{\partial b_j^{(1)}} = \frac{\partial \ell}{\partial z_j}. \quad (51)$$

对 ReLU, $\phi'(z) = \mathbf{1}[z > 0]$ 。对 sigmoid, $\phi'(z) = \sigma(z)(1 - \sigma(z))$ 。

核心要点

反向传播不是新算法, 只是把 $\partial \ell / \partial \theta$ 按计算图从输出往输入传。现代框架(PyTorch、JAX)自动做这件事; 你需要理解的是: **梯度从损失流向参数**, 以及**饱和激活会导致梯度消失**。

10.3 二分类时只改最后一步

若 $\hat{y} = \sigma(u)$ 且用 BCE, 则 $\partial \ell / \partial u = \hat{y} - y$, 与 (39) 相同。其余公式不变。

11 过拟合、正则化与模型选择

11.1 三种数据划分

- **训练集**: 用来算梯度、更新 θ 。
- **验证集**: 用来选超参数、做 early stopping。不能再拿去训练。
- **测试集**: 只在最后报告一次。HEP 里还要小心: 同一批蒙特卡罗被反复调 cut, 也会“偷看测试集”。

交叉验证 (cross-validation) 把数据轮流当验证集, 适合小样本。LHC 分析样本量大, 更常见的是固定划分或 k -fold 仅用于超参数。

11.2 正则化清单

1. L_2 (权重衰减): $\Omega = \frac{\lambda}{2} \|\theta\|^2$ 。
2. L_1 : 促使稀疏。
3. Dropout: 训练时随机把隐藏单元置零。
4. Early stopping。
5. 数据增强: 喷射里可做旋转、软滴度重排等 (需符合物理对称性)。

11.3 偏差、容量与物理先验

在粒子物理中, 把四动量的洛伦兹协变量、红外安全观测量作为输入, 本身就是正则化: 假设类被物理限制住了。反之, 把原始探测器击中一股脑喂给巨大网络, 容量很大, 更需要数据与正则。

12 分类器性能: ROC、AUC 与物理显著性

对分数 $s(\mathbf{x})$ 与阈值 t , 定义

$$\varepsilon_s(t) = P(s \geq t \mid y = 1) \quad \text{真阳性率 / 信号效率,} \quad (52)$$

$$\varepsilon_b(t) = P(s \geq t \mid y = 0) \quad \text{假阳性率 / 本底效率.} \quad (53)$$

ROC 曲线是参数曲线 $(\varepsilon_b(t), \varepsilon_s(t))$ 。AUC 是其下面积: 随机排序时 $\text{AUC} = 1/2$, 完美分类 $\text{AUC} = 1$ 。

容易混淆

AUC 很大并不等于物理分析更好。分析真正关心的是某一工作点上的 $\varepsilon_s/\sqrt{\varepsilon_b}$, 或完整的似然拟合。一个 AUC 略低但在低 ε_b 处更陡的分类器, 对稀有信号搜索往往更有用。

近似显著性(没有系统误差时)

$$Z \approx \frac{S}{\sqrt{B}} = \frac{N\varepsilon_s}{\sqrt{N_b\varepsilon_b}}. \quad (54)$$

系统误差存在时常常用 $S/\sqrt{B + \delta B^2}$ 。机器学习给出的是 $\varepsilon_s, \varepsilon_b$; 是否提高 Z , 还取决于本底估计是否仍然可靠。

13 粒子物理中的典型任务

David Shih 的课几乎一定从 HEP 用例讲起, 而不是从 ImageNet 讲起。下面是最常见的几类。

13.1 监督分类: 喷射标记与信号-本底

输入可以是:

- 高层次观测量: 质量、 N -subjettiness、能量关联函数;
- 低层次: 构成粒子的四动量列表(点云)、或喷射图像。

标签来自蒙特卡罗: 这是 b -jet vs. light-jet、顶夸克喷射 vs. QCD 喷射、或 $h \rightarrow \tau\tau$ vs. 本底等。

例子 13.1 (理想监督). 若你有纯信号模拟与纯本底模拟, 就直接训 BCE 分类器。由命题 5.1, 它逼近 p_S/p_B 。这是所有后续“弱监督变体”的对照基线(fully supervised benchmark)。

13.2 回归

能量回归、质量回归、探测器校准。损失常用 MSE 或分位数损失(预测区间)。

13.3 生成模型与快速模拟

用神经网络学习 $p(\mathbf{x})$, 从而快速抽样事件, 替代部分 GEANT 模拟。这需要密度估计, 见下一节。

13.4 与模型无关的搜索

新物理可能不像任何现有基准模型。于是不再训练“特定 BSM vs. SM”, 而是问: **数据是否偏离我们对 SM 本底的理解**。这是 Shih 工作的核心区。

14 密度估计与生成模型(听课预备)

定义 14.1 (密度估计). 给定 $\{\mathbf{x}_i\}_{i=1}^n \sim p$, 构造 $\hat{p}(\mathbf{x}) \approx p(\mathbf{x})$ 。若还能从 $\hat{p}$ 抽样, 就称为生成模型(generative model)。

14.1 从直方图到神经网络

- 一维: 直方图、KDE。
- 高维: 直方图崩溃(维数灾难)。需要参数化密度。

归一化流(normalizing flow)是 HEP 里很常见的一类: 取简单底分布 $p_u(\mathbf{u})$ (如标准正态), 学习可逆映射 $\mathbf{x} = f_\theta(\mathbf{u})$, 则

$$p_\theta(\mathbf{x}) = p_u(f_\theta^{-1}(\mathbf{x})) \left| \det \frac{\partial f_\theta^{-1}}{\partial \mathbf{x}} \right|. \quad (55)$$

训练目标仍是 NLL: $-\sum_i \log p_\theta(\mathbf{x}_i)$ 。优点是既有密度值, 又能抽样。CATHODE 的 “outer density estimation” 常用这类模型(以及后来的扩散模型等)。

14.2 条件密度

物理里几乎总是条件密度 $p(\mathbf{x} | m)$, 其中 m 是不变质量等共振变量。学会 $p(\mathbf{x} | m)$ 后, 可以在信号区的 m 上插值本底密度。这是 ANODE/CATHODE 的技术起点。

听课提示

听到 *density estimator*、*flow*、*generative model* 时, 先问两句: 它输出的是密度值 $\hat{p}(\mathbf{x})$, 还是只会抽样? 它是不是条件于质量 m ? 异常探测方法的差异往往就在这里。

15 弱监督与异常探测: CWoLa 与 CATHODE

15.1 问题

监督分类需要信号模拟。若信号模型错了, 分类器会对 “错的信号” 最优。异常探测改为:

在尽量少的信号假设下, 找数据中相对本底的局域过量。 (56)

经典 bump hunt 是在质量 m 上找峰。机器学习要回答: 在质量以外的特征 $\mathbf{x}$ 上, 能否增强这个峰。

15.2 CWoLa: 用混合样本做弱监督

CWoLa = Classification Without Labels。核心引理: 若两个混合样本

$$p_1(\mathbf{x}) = f_1 p_S(\mathbf{x}) + (1 - f_1) p_B(\mathbf{x}), \quad (57)$$

$$p_2(\mathbf{x}) = f_2 p_S(\mathbf{x}) + (1 - f_2) p_B(\mathbf{x}), \quad (58)$$

且 $f_1 \neq f_2$, 则区分 p_1 与 p_2 的最优分类器, 等价于区分 p_S 与 p_B 的最优分类器(分数是同一似然比的单调函数)。

CWoLa hunting: 把质量信号区 SR 与边带 SB 当成两个混合样本。若信号只出现在 SR, 则 $f_{SR} > f_{SB} \approx 0$ 。训练 “SR vs. SB” 分类器, 就可能把信号从本底中挑出来。

容易混淆

若特征 $\mathbf{x}$ 与质量 m 相关, 本底在 SR 与 SB 的 $p_B(\mathbf{x} | m)$ 不同, CWoLa 会把这种相关误当成信号。这是该方法最重要的系统误差来源。

15.3 ANODE

在边带上学习条件密度 $p(\mathbf{x} | m)$, 插值到信号区得到本底模型 $p_B(\mathbf{x} | m)$; 再在信号区估计数据密度 $p_{\text{data}}(\mathbf{x} | m)$ 。异常分数取

$$R(\mathbf{x}, m) = \frac{p_{\text{data}}(\mathbf{x} | m)}{p_B(\mathbf{x} | m)}. \quad (59)$$

这直接逼近 Neyman–Pearson 最优。难点: 高维密度估计本身很难, 两个密度的比更不稳定。

15.4 CATHODE

CATHODE = Classifying Anomalies THrough Outer Density Estimation (Shih 等, PRD 106, 055006 (2022))。它把 ANODE 与 CWoLa 的优点合在一起:

1. 在边带(outer region)训练条件密度估计器, 得到 $p_B(\mathbf{x} | m)$ 。
2. 把该密度插值到信号区, 并从中**抽样**出一组人造本底事件。
3. 在信号区训练分类器: 真实数据 vs. 人造本底。

第三步回到分类 (通常比直接除两个密度更稳), 而人造本底比原始边带数据更接近 SR 里的 $p_B(\mathbf{x} | m)$, 从而减轻 CWoLa 的相关问题。理想情况下, 该分类器逼近 p_{data}/p_B , 也就是最优异常探测分数。

核心要点

三句话记住 Shih 路线: **监督分类**逼近 p_S/p_B ; **CWoLa** 用两个不同纯度的混合逼近同一个比; **CATHODE** 用边带密度估计在信号区制造本底样本, 再分类。听课重点是: 每一步在逼近哪个分布、依赖什么假设、假设破掉时哪里会假信号。

15.5 LHC Olympics 与 R&D 数据集

课堂很可能用 LHC Olympics 的公开 R&D 集做演示: 一个共振质量附近的新物理喷射对, 加上 QCD 本底。预习时只需知道: 有一个“信号区质量窗口”, 以及若干喷射子结构特征。不必提前把论文读完, 但应能看懂“SR / SB / features”这三张图。

16 课堂可能出现的公式与术语

把下列式子看熟, 课堂上只需把记号对上。

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L} \quad \text{梯度下降} \quad (60)$$

$$\sigma(z) = (1 + e^{-z})^{-1} \quad \text{sigmoid} \quad (61)$$

$$\mathcal{L}_{\text{BCE}} = -[y \log \hat{p} + (1 - y) \log(1 - \hat{p})] \quad \text{二元交叉熵} \quad (62)$$

$$\hat{p}_k = \text{softmax}(\mathbf{z})_k \quad \text{多类} \quad (63)$$

$$\frac{p_S(\mathbf{x})}{p_B(\mathbf{x})} \quad \text{最优判别分数} \quad (64)$$

$$p(\mathbf{x}) = p_u(f^{-1}(\mathbf{x})) |\det Df^{-1}| \quad \text{归一化流} \quad (65)$$

$$R = \frac{p_{\text{data}}(\mathbf{x} | m)}{p_B(\mathbf{x} | m)} \quad \text{异常分数} \quad (66)$$

高频词(完整中英对照见第 20 节): *supervised / unsupervised / weakly supervised, loss, gradient descent, learning rate, overfitting, regularization, classifier, ROC, AUC, likelihood ratio, density estimation, generative model, sideband, signal region, anomaly detection, CWoLa, CATHODE, ANODE, jet tagging.*

17 常见困惑

1. “神经网络能拟合任何函数, 所以一定更好。”
万能近似不管泛化。数据有限时, 线性模型或物理观测量加 BDT 可能更稳。

2. “训练损失下降就是成功。”
必须看验证集。训练损失下降、验证损失上升 = 过拟合。
3. “逻辑回归是非线性模型。”
概率是 z 的非线性函数, 但决策边界是线性的。
4. “AUC 高 = 发现新物理。”
AUC 在模拟上算。真实分析还要本底估计、系统误差、试探惩罚(look-elsewhere)。
5. “无监督等于不需要假设。”
异常探测总有假设: 信号在质量上局域、本底在边带可插值、特征与质量的相关可忽略或可建模。把假设说清楚, 比宣称 “model independent” 更重要。
6. “分类器和密度估计是两套无关技术。”
由命题 5.1, 最优分类器就是密度比。CATHODE 正是先密度、后分类。
7. “交叉熵和最大似然是两件事。”
对分类的离散标签分布, 它们是同一件事。
8. 把 $y = \pm 1$ 与 $y = 0/1$ 的公式混用。
损失形式不同。看老师的标签约定再套公式。

18 听课重点

四讲时间紧。建议把注意力放在下面几条, 而不是记网络层数。

1. 第一、二讲(17 日): 监督学习叙事是否从损失 + 梯度讲起; 有没有强调似然比; 喷射标记或简单分类演示。
2. 第三、四讲(18 日): 生成模型/密度估计如何引入; 异常探测的假设(SR/SB); CWoLa、ANODE、CATHODE 的比较表。
3. 每当出现一个方法, 自己填空:
输入是什么? 标签从哪来? 损失是什么? 它在逼近哪个比? 主要系统误差是什么?
4. 记录老师用的数据集(LHC Olympics? ATLAS Open Data? 自模拟?)和评价曲线(ROC 还是 significance improvement)。
5. 讨论时段优先问: 特征-质量相关如何处理、如何避免在 SR 上过拟合波动。

听课提示

若某张幻灯片出现 CATHODE 流程图, 请当场在本子上画: SB $\rightarrow$ 条件密度 $\rightarrow$ 插值到 SR $\rightarrow$ 抽样本底 $\rightarrow$ 数据 vs. 抽样的分类器 $\rightarrow$ 异常分数。能默画, 这四讲就没有白听。

19 进一步学习路线

19.1 课前(数小时)

1. 亲手用 20 行 Python 实现逻辑回归的梯度下降, 画决策边界。
2. 读一遍二元交叉熵对 $\hat{p}$ 的导数, 确认是 $\hat{p} - y$ 。
3. 浏览 CATHODE 论文引言与 Figure 1(arXiv:2109.00546 / PRD 106, 055006)。

19.2 课中对照

- 基础教材: Bishop *Pattern Recognition and Machine Learning* 第 3–5 章; 或 Goodfellow, Bengio, Courville *Deep Learning* 第 4–6 章。
- HEP 综述: Guest, Cranmer, Whiteson, *Deep Learning and its Application to LHC Physics*; 以及机器学习 Living Review (hep-ph)。

19.3 课后深入

1. 弱监督: Metodiev, Nachman, Thaler, CWoLa (JHEP 2017)。
2. 密度异常探测: ANODE (Nachman, Shih, 2020); CATHODE (Hallin et al. 2022)。
3. 生成模型: 归一化流综述; 以及喷射生成 (CaloGAN、JetNet 等)。
4. 实践: PyTorch 写一个 MLP 做公开喷射分类; 再试 LHC Olympics R&D。

不要一上来就读 Transformer 综述。对这门课, **似然比 + 密度估计 + SR/SB** 比最新架构重要得多。

20 英文术语表

English	中文
supervised / unsupervised learning	监督 / 无监督学习
weakly supervised learning	弱监督学习
training / validation / test set	训练 / 验证 / 测试集
feature, label, sample / event	特征、标签、样本 / 事件
hypothesis class	假设类
loss function	损失函数
empirical risk minimization (ERM)	经验风险最小化
maximum likelihood estimation (MLE)	极大似然估计
mean squared error (MSE)	均方误差
binary cross-entropy (BCE)	二元交叉熵
softmax	归一化指数(软最大值)
gradient descent / SGD / mini-batch	梯度下降 / 随机梯度下降 / 小批量
learning rate	学习率
backpropagation	反向传播
activation function; ReLU	激活函数; 线性整流
neural network; MLP	神经网络; 多层感知机
overfitting / underfitting	过拟合 / 欠拟合
regularization; weight decay	正则化; 权重衰减
early stopping	早停
classifier / regressor	分类器 / 回归器
decision boundary	决策边界
ROC curve; AUC	ROC 曲线; 曲线下面积
working point; efficiency	工作点; 效率
likelihood ratio	似然比
Neyman–Pearson lemma	奈曼–皮尔逊引理
density estimation	密度估计
generative model	生成模型
normalizing flow	归一化流
anomaly detection	异常探测
signal region (SR) / sideband (SB)	信号区 / 边带
background interpolation	本底插值
jet tagging	喷射标记
bump hunt	共振峰搜索
CWoLa, ANODE, CATHODE	弱监督与异常探测算法名

声明: 本讲义为暑期学校课前预习材料, 由学生侧整理, 不代表授课人立场。公式与术语以课堂为准。CATHODE 等方法的细节请参阅原始论文。